

Končni povzetek

Problem raziskave

Cilj seminarske naloge je bil razviti napovedni model za klasifikacijo plesnih hitov na Spotify platformi ter identificirati ključne akustične značilke, ki vplivajo na uspešnost skladb. Vzorec je zajemal 89.740 skladb (44,6 % plesni hiti, 55,4 % ostale). Ključni izziv je bila visoka multikolinearnost spremenljivk ($VIF > 10$ pri tempo in energy) ter nelinearna ločljivost razredov, kar je onemogočilo uporabo klasičnih linearnih pristopov.

Najboljši modeli

Najboljši model je **XGBoost** z 81,16 % natančnostjo ($AUC = 0,8969$), sledita mu **Random Forest** (80,93 %, $AUC = 0,8941$) in **k-NN** (78,82 %, $AUC = 0,8729$). XGBoost je dosegel najvišji priklic (79,5 %) in najnižje informacijske kriterije ($AIC = 14.502,74$), kar potrjuje njegovo superiorno sposobnost zaznavanja nelinearnih pragov in interakcij. Logistična regresija (68,94 %) in nevronska mreža (78,39 %) sta bili manj učinkoviti zaradi linearnih predpostavk oz. omejitev pri tabelaričnih podatkih.

Ključne spremenljivke za optimizacijo

Analiza pomembnosti je identificirala **valence** (čustvena pozitivnost) kot najmočnejši napovedovalec z LASSO koeficientom 1,077. Dodatne kritične spremenljivke z nelinearnimi odnosi so:

- **Energy in Loudness:** točka nasičenja pri 0,7 oz. -4 dB
- **Liveness:** močna negativna korelacija (optimalno $< 0,20$)
- **Acousticness:** optimalno območje 0,3–0,65
- **Speechiness:** spodnji prag pri 0,2

Presenetljivo **tempo** ni pokazal statistično pomembnega linearnega vpliva.

Učinki implementacije sprememb

Testiranje sedmih optimizacijskih scenarijev je pokazalo:

- **"Studijska perfekcija"** (nizek liveness, optimalen loudness in povišana pozitivnost): +28,16 % (+2.288 skladb)
- **"Vokalna strategija"** (speechiness $> 0,2$): +17,92 % (+1.456 skladb)
- **"Optimizacija valence"** (valence $> 0,65$): +14,64 % (+1.189 skladb)
- **"Napačna odločitev"** (visok liveness za live album): -34,69 % (-2.818 skladb)

Različni modeli so različno ocenjevali obseg sprememb (XGBoost +28 %, RF +9 %, k-NN +8 %), kar pripisujemo XGBoost sposobnosti zaznavanja sinergijskih učinkov.

Izboljšava Six Sigma stopnje

XGBoost je dosegel največjo izboljšavo: DPMO znižan iz 547.359 na 419.880 (-23,3 %), sigma nivo povečan iz $1,38\sigma$ na **$1,70\sigma$** (+0,32 σ). Random Forest (+0,10 σ) in k-NN (+0,09 σ) sta pokazala zmernejše izboljšave. Kljub napredku vsi modeli ostajajo pod 2σ nivojem, kar pomeni, da proces še vedno proizvaja ~42 % "defektov" in je daleč od industrije-standardov ($\geq 3\sigma$).

Priporočila za implementacijo

Implementacija je upravičena s sledečimi ukrepi:

1. **Uvedba XGBoost pre-screening sistema:** Demo posnetki z napovedno verjetnostjo < 50 % se vrnejo v studio za optimizacijo.
2. **Preusmeritev vlaganj:** Proračun za live albume preusmeriti v studijsko produkcijo za doseganje optimalne loudness (-4 dB) in nizkega liveness ($< 0,20$).
3. **Vokalna prioriteta:** Vse skladbe morajo doseči speechiness $> 0,2$ z vključitvijo vokalnih elementov.
4. **Hibridni pristop:** Kombinacija sintetičnih in akustičnih instrumentov za acousticness 0,3–0,65.
5. **Svoboda pri tempu:** Producenti naj obdržijo ustvarjalno svobodo pri BPM izbiri.
6. **Postopna uvedba:** Pilotni projekt na 200–300 skladbah z evalvacijo po šestih mesecih.

Pričakovani ROI je pozitiven, **povečanje deleža potencialnih hitov za 23 % pri nespremenjenih stroških** predstavlja pomembno konkurenčno prednost. Za doseg sigma nivoja $\geq 3\sigma$ so potrebne nadaljnje iteracije z vključitvijo tržnih trendov in geografskih preferenc.